

Treball de Fi de Grau

Grau en Enginyeria en Tecnologies Industrials (GETI)

Estudi i desenvolupament d'una arquitectura d'intel·ligència artificial neuromòrfica basada en xarxes neuronals de polsos (SNNs).

MEMÒRIA

27 de novembre de 2025

Autor: Alejandro Pérez Hernández

Director: Álvaro Gómez Pau

Convocatòria: data



ETSEIB

Escola Tècnica Superior
d'Enginyeria Industrial de Barcelona



Resum

1 Pàgina. Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Índice

1. Prefaci	7
2. Introducció	9
2.1. Objectius	9
2.2. Abast del projecte	9
3. Context i marc teòric	11
3.1. Orígens de la Intel·ligència Artificial	11
3.2. Naixement xarxes neuronals	12
3.3. Machine Learning i Deep Learning	14
3.4. Xarxes neuronals artificials modernes (ANNs)	16
3.5. Limitacions de les ANNs	19
3.6. Xarxes neuronals de polsos (SNNs)	20
4. Fonament tècnics de les SNNs	21
5. Desenvolupament pràctic	23
5.1. Entrenament d'una ANN per MNIST	23
5.2. Conversió ANN → SNN	23
5.3. Disseny d'una arquitectura hardware neuromòrfica (Si dona temps)	23
6. Resultats	25
7. Pressupost	27
8. Impacte ambiental	27
Conclusions	27
Agraïments	27
Anex	32

Índice de figuras

1. Una imatge del logo de l'ETSEIB	7
--	---

1. Prefaci

Per no repetir informació és millor referir-se a altres apartats I recorda, sempre és important citar a la bibliografia [1].

La bibliografia ha d'estar ordenada, en teniu un exemple a la pàgina



Figura 1: Una imatge del logo de l'ETSEIB

2. Introducció

2.1. Objectius

2.2. Abast del projecte

Com hi ha coses escrites en aquest apartat, el següent començarà en una pàgina senar nova.

3. Context i marc teòric

Per entendre com funciona la intel·ligència artificial actual, i especialment aquelles basades en estructures que simulen el funcionament del cervell humà com les xarxes neuronals de polsos (SNNs), és essencial mirar enrere i comprendre d'on provenen, i com han estat concebudes des dels seus inicis. La manera en com es va definir i enfocar la intel·ligència artificial en els seus primers anys, així com la posterior evolució dels models d'intel·ligència computacional i els diferents mètodes d'aprenentatge emprats al llarg de la història, continuen tenint un profund impacte sobre les tecnologies i els paradigmes utilitzats avui dia. La història de la intel·ligència artificial no és només una successió d'avenços tècnics, sinó també un reflex dels diferents models amb què la ciència ha intentat descriure el pensament, l'aprenentatge, la intel·ligència i la consciència humana. Explorar els orígens de la IA ens permet identificar els seus punts forts, els seus límits, i explica per què, després de dècades de desenvolupament en una direcció, estem tornant a idees fortament inspirades en la neurobiologia. Aquesta retrospectiva ens ajuda a situar les arquitectures neuromòrfiques dins d'un context evolutiu, i a entendre com aquestes poden donar una resposta a les limitacions dels enfocaments tradicionals utilitzats en l'actualitat.

3.1. Orígens de la Intel·ligència Artificial

Els primers esbossos del que avui dia entenem com a intel·ligència artificial sorgeixen l'any 1943 quan, amb la premissa de crear un "cervell electrònic", el neurofisiòleg Warren McCulloch i el matemàtic Walter Pitts publiquen *A Logical Calculus of the Ideas Immanent in Nervous Activity* [2], un article que proposa un model matemàtic del sistema nerviós, a base d'una xarxa d'elements lògics simples, el que més tard es coneixerien com "Neurones Artificials". Aquestes neurones, tot i fer-ho d'una manera simple basada en la lògica matemàtica, funcionen de manera similar a com avui dia funcionen les xarxes neuronals tradicionals, agafant "l'input" o entrada, realitzant-li una suma ponderada en cada neurona amb una funció llindar que filtra el moviment d'informació entre neurones, i generant "l'output" o sortida desitjada. Aquest article marca l'inici i estableix les bases de les xarxes neuronals artificials, obrint la porta a la idea que el pensament pot ser simulat per màquines.

El primer en plantejar aquest paradigma és Alan Turing en el seu article *Computing Machinery and Intelligence* [3]. En aquest, Turing planteja la pregunta de "Poden les màquines pensar?" introduint el que ara es coneix com el Test de Turing, un experiment de comportament que ell anomena *Imitation Game* (joc d'imitació). Amb aquest experiment proposa que, si una màquina pot imitar les respostes d'un humà de manera suficientment convincent perquè un humà no pugui distingir de manera fiable d'una persona, aquesta màquina podrà ser considerada intel·ligent. Turing també introdueix el concepte de *self-teaching machines*, proposant la idea d'una màquina capaç de ser entrenada de manera similar a un infant humà, a base de recompenses i/o càstigs.

Basant en les idees fonamentals introduïdes al article de Turing, la universitat de Dartmouth marca el naixement formal de la intel·ligència artificial com a camp al 1956 amb el *Dartmouth Summer Research Project on Artificial Intelligence* [4], un programa proposat per John McCarthy, Marvin Minsky, Nathaniel Rochester i Claude Shannon un any abans, que es basa en la conjectura de que tots els aspectes de l'aprenentatge humà es poden descriure amb prou precisió perquè una màquina el simuli. Aquest projecte reuneix als principals pensadors de les matemà-

tiques, la informàtica, la neurociència i la ciència cognitiva de la època, i estableix per a dècades de recerca i innovació en aquest nou camp.

Basant-se en els conceptes fonamentals introduïts per Turing i formalitzats durant el Dartmouth Summer Research Project on Artificial Intelligence, el camp de la intel·ligència artificial entra en la seva primera fase important: la IA simbòlica, també coneguda com a *Good Old-Fashioned AI* (GOFAI). Dominant la recerca en IA des de mitjans dels anys cinquanta fins a mitjans dels anys noranta, aquest enfocament es centra en representar el coneixement mitjançant símbols llegibles pels humans i manipular-los mitjançant la lògica i la cerca heurística. Entre els primers programes importants basats en aquest enfocament s'inclou el *Logic Theorist* o *The Logic Theory Machine* [5] (1956), d'Allen Newell, Herbert A. Simons i Cliff Shaw, el primer programa en demostrar les teories proposades per Turing, aconseguint un sistema d'intel·ligència artificial capaç de raonament automatitzat demostrant teoremes matemàtics de *Principia Mathematica* [1]. Aprofitant l'èxit del programa, Newell, Simons i Shaw desenvolupen el *General Problem Solver* (GPS) [6], un sistema més versàtil que pretén resoldre una àmplia gamma de problemes mitjançant les estratègies heurístiques. Aquests esforços no només demostren que les màquines poden realitzar tasques tradicionalment associades amb el raonament humà, sinó que també inspiren futurs projectes de recerca i porten una creixent atenció per part del món acadèmic i del públic al camp emergent de la intel·ligència artificial.

Cimentant-se en els fonaments establerts per les primeres instàncies d'IA simbòlica i el treball teòric sobre neurones artificials realitzat per McCulloch i Pitts, la dècada dels 50 veu també l'aparició de màquines d'autoaprenentatge, programes amb la capacitat d'adaptar-se basats en experiències en lloc de basar-se únicament en regles fixes com les màquines tradicionals. El programa de dames d'Arthur Samuel (1952-1955) [7] marca un punt d'inflexió en el camp, demostrant l'habilitat de les màquines per aprendre i millorar sense ser explícitament programades per això, de manera similar al que proposava Turing d'ensenyar a una màquina com un infant. Més o menys al mateix temps, el model *Perceptron* [8] va ampliar idees de les neurones McCulloch-Pitts a xarxes neuronals entrenables, destacant una via paral·lela al raonament simbòlic. Altres innovacions, com l'experiment de traducció automàtica de Georgetown-IBM (1954) [9], la primera demostració d'una màquina capaç de traduir frases senceres del rus a l'anglès, els primers programes de joc i el sistema *STUDENT* [10] per resoldre problemes d'àlgebra, van demostrar una creixent diversitat en els enfocaments de la IA, combinant mètodes estadístics, simbòlics i heurístics. Aquests desenvolupaments marquen el canvi del camp de la intel·ligència codificada a mà a sistemes capaços d'aprendre, adaptar-se i millorar, trets característics de la intel·ligència artificial moderna.

3.2. Naixement xarxes neuronals

Les xarxes neuronals són models computacionals inspirats pel funcionament del cervell humà. Consisteixen en grups de neurones artificials anomenades nodes, agrupades per capes. Aquestes, a través d'un *input* o entrada i mitjançant sumes ponderades de node a node aconsegueixen processar informació. El primer model del que avui dia anomenariem xarxa neuronal apareix amb el model del Perceptró (*Perceptron* [8]) a mitjans dels anys 50. Aquest, concebut l'any 1957 per Frank Rosenblatt, és un model de neurona artificial que utilitza un classificador binari conegut com a funció lllindar (*threshold function*), una funció que utilitza un nombre d'entrades ($x_1 \dots x_n$), pesos ($w_1 \dots w_n$) i un valor lllindar o biax (b), junt amb la funció de Heaviside, per

determinar l'activació de la neurona.

$$f(\mathbf{x}) = h\left(\sum_{n=1}^N (x_n w_n) + b\right) \quad (1)$$

On $\sum_{n=1}^N (x_n w_n) + b = z$. D'aquesta manera, la neurona s'activa ($f(x) = 1$) si $z \geq 0$ i queda inactiva ($f(x) = 0$) si $z < 0$. Aquesta regla simple estableix si la informació s'ha de transmetre a la següent neurona o no, repetint aquest procés fins a arribar a la sortida (el valor de la darrera neurona) desitjada. Aquest model permet per primera vegada que una màquina aprengués de manera autònoma un criteri de classificació a partir d'exemples, en lloc de dependre exclusivament de regles manuals escrites per humans. Concretament, possibilita ajustar pesos i biaix a partir de dades d'entrenament mitjançant una regla local d'actualització, i l'adaptació i millora amb experiència sense necessitat de reprogramació explícita. A més, opera de manera eficient i en línia, actualitzant pesos per cada exemple, cosa que el fa útil per a sistemes adaptatius en temps real. Al mateix any de la seva concepció, l'any 1957, Frank Rosenblatt simulà un model del Perceptró en un IBM 704 al laboratori aeronàutic de Cornell (*Calspan*), on es va provar la utilitat d'aquest model, el que serveix per cridar l'atenció del departament de la marina dels Estats Units (ONR), qui més tard finançaria el projecte per crear una màquina dissenyada específicament per executar aquests models, el *Mark I Perceptron*. Aquest model, però, no era pas perfecte. A causa de la seva arquitectura simple, el perceptró només pot separar les dades amb un hiperplà, és a dir, una línia (en 2D), un pla (en 3D), etc. Per tant, no podia resoldre problemes no linealment separables, cosa que va resultar problemàtica, al no poder resoldre la funció lògica bàsica XOR (exclusiva O). A més, la seva capacitat d'aprenentatge era limitada, doncs només podia aprendre patrons molt simples. Marvin Minsky i Seymour Papert van assenyalar totes aquestes debilitats al seu llibre *Perceptrons* (1969) [11], fet que va provocar que molts investigadors i finançadors perdessin l'interès en el camp de la intel·ligència artificial. Això va donar lloc a un període conegut com l'hivern de la IA, caracteritzat per la desinversió i la poca investigació en aquest àmbit, que es va allargar fins a mitjans dels anys 80.

Després de la desil·lusió causada per les limitacions del perceptró simple, alguns investigadors van continuar explorant la possibilitat de construir xarxes neuronals més potents. Ja a finals dels anys 50 i principis dels 60, es va començar a parlar de xarxes amb múltiples capes, però no es disposava d'un mètode eficient per entrenar-les, cosa que en limitava enormement l'aplicació pràctica. Tot i aquestes dificultats, la idea va quedar latent durant dècades fins que, l'any 1986, David E. Rumelhart, Geoffrey Hinton i Ronald J. Williams van publicar *Learning representations by back-propagating errors* [12], un article que redescobria i formalitzava l'algorisme de retropropagació de l'error (*backpropagation*) com a eina per entrenar xarxes neuronals multicapa. Aquest moment dona una base sòlida i funcional a un model que fins llavors havia estat només una idea prometedora: el perceptró multicapa (MLP).

El perceptró multicapa consisteix en una xarxa de neurones artificials organitzades en diverses capes consecutives, una d'entrada, una o més capes ocultes, i una de sortida. Cada neurona d'una capa està connectada amb totes les neurones de la capa següent mitjançant pesos, de manera similar al Perceptró simple, que regulen el pes de cada connexió. Quan s'introdueixen dades a la xarxa, aquestes passen per les capes de manera seqüencial. Cada neurona calcula una combinació lineal de les seves entrades i hi aplica una funció d'activació no lineal, normalment

la funció de Sigmoid [13] o la funció ReLU [14], que permet al sistema capturar patrons complexos. El gran repte, però, era saber com ajustar els pesos per tal que la xarxa produís resultats correctes. La retropropagació permet solucionar aquest problema. Aquesta funciona de manera que, una vegada la xarxa produeix una sortida, es compara amb la sortida esperada i es calcula un error. Aquest error es propaga cap enrere des de la capa de sortida fins a les primeres capes, utilitzant el càlcul del gradient de l'error respecte a cada pes. Això permet modificar els pesos mitjançant un algoritme d'optimització com el descens del gradient, de manera que l'error es vagi reduint a cada iteració. Aquest procés es repeteix milers o milions de vegades, amb moltes dades diferents, fins que la xarxa aprèn a realitzar la tasca desitjada amb gran precisió.

Aquests avenços suposen una veritable revolució, doncs per primera vegada, les xarxes neuronals eren capaces de resoldre problemes complexos, no lineals, i amb moltes variables, cosa que va reactivar l'interès pel camp de la IA i va posar les bases del Deep Learning que avui coneixem.

3.3. Machine Learning i Deep Learning

El *Machine Learning* (aprenentatge automàtic) és una branca de la intel·ligència artificial dedicada a l'estudi i al desenvolupament d'algorismes estadístics que aprenen a partir de dades. Aquestes algorismes permeten a les màquines generalitzar la informació obtinguda per resoldre tasques i prendre decisions en tasques per a les quals no han estat explícitament programades. El terme Machine Learning l'introdueix per primer cop Arthur Samuel a la dècada dels 1950, per descriure programes o màquines capaces d'aprendre i millorar el seu rendiment mitjançant l'experiència. La primera demostració de que això era possible fou el ja mencionat programa de dames [7] del mateix Arthur Samuel. Durant les següents dècades, es van desenvolupar models i tècniques, com ara el perceptró i la retropropagació, que establirien els fonaments teòrics del Machine Learning, i popularitzarien el seu ús per l'entrenament de models computacionals durant la dècada dels 1970. El Machine Learning utilitza principalment tres diferents paradigmes d'aprenentatge automàtic.

L'aprenentatge supervisat (SL), on l'algorisme aprèn a relacionar una entrada amb una sortida basant-se en conjunts d'exemples etiquetats, amb la finalitat de que aquest algorisme sigui capaç de predir etiquetes o valors per a noves dades de sortida en base a la entrada. Aquest model és el més estable, però no permet modelar decisions seqüencials.

L'aprenentatge no supervisat o aprenentatge autosupervisat (UL o SSL), que a diferència del supervisat utilitza dades sense etiquetes per extraure estructures estadístiques o patrons de les dades. Aquests algorismes no tenen la mateixa capacitat per realitzar tasques concretes com els entrenats per aprenentatge supervisat i poden requerir d'un aprenentatge supervisat reduir per poder realitzar-les, però al no haver d'etiquetar les dades i relacionar-les manualment amb la sortida, són bastant més fàcils d'entrenar, el que redueix el cost econòmic de fer-ho, especialment per a grans bases de dades no etiquetades.

Per últim, l'aprenentatge per reforç (RL), un mètode d'aprenentatge es basa en la psicologia conductista. En aquest paradigma, un agent o màquina rep informació de l'entorn (entrada), i emet accions (sortida). Un interprete, ja sigui humà o una funció de recompensa, retorna noves observacions (entrades), i una recompensa. L'objectiu de l'agent serà doncs aprendre un patró que maximitzi la recompensa acumulada, mitjançant l'exploració i l'explotació de l'entorn,

actualitzant de manera contínua els seus paràmetres segons l'experiència obtinguda. Aquest model, tot i ser ideal per resoldre problemes seqüencials i iteratius, és més costós, i pot presentar problemes d'inestabilitat i/o no convergència, el qual pot rendir el model inutilitzable per alguns usos. Cada paradigma té fonaments teòrics i aplicacions pròpies i ha evolucionat amb contribucions històriques que van definir les tècniques i els reptes actuals.

Malgrat l'estancament provocat per les limitacions del perceptró i la crítica de Minsky i Papert als anys 60, la introducció i formalització de mètodes d'entrenament per a xarxes multicapa (notablement la retropropagació a mitjans dels anys 80) i, més tard, la disponibilitat massiva de dades i capacitat de càlcul que apareixen amb la popularització de l'internet impulsen l'avenç i l'expansió del camp, donant lloc al que avui anomenem Deep Learning. Deep Learning (DL) és una subàrea del Machine Learning que empra xarxes neuronals profundes, models multicapa amb moltes capes ocultes, normalment centenars o milers, per aprendre representacions jeràrquiques i automàtiques de les dades. La principal avantatge d'aquest tipus d'aprenentatge i de l'ús de xarxes neuronals profundes, és la seva capacitat d'aprendre característiques directament a partir de dades brutes, com ara dades no etiquetades i no estructurades, el que les fa ideals per al seu entrenament amb algorismes d'aprenentatge no supervisat, aconseguint resultats similars als que es poden aconseguir utilitzant algorismes d'aprenentatge supervisat amb xarxes més simples, sense la necessitat d'estructurar i etiquetar les dades. Això es fa possible gràcies a les profundes desenvolupades als anys 80, com el perceptró multicapa, i a algorismes d'entrenament eficaços com la retropropagació combinada amb variants del descens de gradient (SGD, Adam, RMSprop) desenvolupats paral·lelament. Aquestes arquitectures permeten la creació d'arquitectures i aplicacions que modelaran les següents dècades de desenvolupament del camp d'estudi de la intel·ligència artificial. D'aquestes tecnologies, destaquen les CNNs, xarxes neuronals convolucionals, les RNNs, o xarxes recurrents i variants, i més endavant els transformers.

Les CNNs, o xarxes neuronals convolucionals, són xarxes dissenyades especialment per processar dades amb estructura espacial o temporal, com ara imatges, vídeos o àudio, de manera eficient. Les CNNs, proposades per primer cop a l'any 1980 per Kunihiko Fukushima, amb el seu "neocognitron" [15], model que era basat en el seu model previ d'elements de llinar analògics per models de visió [16] presentat al 1969, i utilitzades per primer cop a l'any 1989 per Yann LeCun [17], amb el seu model LeNet-5, dissenyat per a la classificació de caràcters manuscrits, el primer exemple d'una xarxa convolucional aplicada amb èxit. Fukushima, basant-se en les observacions del neurocientífic David Hubel i el neurofisiòleg Torsten Wiesel sobre com certes neurones al cervell responen en exposar un individu a certs estímuls visuals específics, va proposar la idea que podria existir un model jeràrquic per processar la informació visual. El model que proposa utilitza capes de convolució, capes que apliquen filtres a l'entrada per extraure característiques locals. Funciona transformant un tensor d'entrada (per exemple, una imatge amb amplada $\times$ alçada $\times$ canals (com ara, els colors dels píxels)) en un conjunt de mapes d'activació (feature maps) mitjançant operacions lineals seguides d'una no-linealitat. Primer, aplica els filtres, que són petites matrius de pesos, per exemple de 3×3 , a parts del tensor d'entrada, i calcula el producte. Aquest valor representa un punt del mapa d'activació. Aquest mateix filtre, sense canviar els pesos, es mou per calcular un altre punt de la entrada, fins a tenir tots els productes de tots els píxels de la imatge calculats, i amb tots aquests forma el mapa. Aquest procés es repeteix per a cada filtre, donant com a resultat diverses capes. Després, a aquestes capes se li aplica un biaix i s'aplica una funció d'activació per introduir no linealitat a cada capa. D'aquesta manera, podem aconseguir capes amb filtres més grans, que puguin detectar grans canvis de color en una imatge, permeten determinar contorns de grans objectes, i

capes amb filtres més petits, que permeten diferenciar entre petits canvis a la imatge, cosa que, combinant-les, permet la identificació d'objectes en una imatge. És per això que aquests tipus de xarxes són les principalment utilitzades en el món de la visió per computador.

Les RNNs, o xarxes neuronals recurrents, apareixen també a principis dels anys 1980, a mans de Rumelhart que, juntament amb David McClelland i Geoffrey Hinton, desenvolupa un algoritme de retropropagació a l'any 1986, presentat a l'article *Learning Representations by Back-Propagating Errors* [12]. A l'article, Rumelhart introdueix les xarxes neuronals recurrents com una extensió natural de les xarxes neuronals convencionals com l'MLP (Multi Layer Perceptrón), amb l'objectiu de poder tractar dades seqüencials o temporals, és a dir, informació on l'ordre dels elements és rellevant. A diferència de les xarxes tradicionals, on el flux d'informació va en una única direcció, d'una entrada cap a una sortida, les RNNs tenen connexions recurrents que permeten que la sortida d'una neurona en un instant de temps pugui influir en el seu estat en instants posteriors, es a dir, que la sortida de cada neurona no només depèn de la entrada, sinó que també depèn de les entrades ha tingut anteriorment. D'aquesta manera, la xarxa manté una mena de "memòria" interna que li permet emmagatzemar informació del passat i utilitzar-la per processar noves entrades.

Aquesta capacitat de recordar el context fa que les RNNs siguin ideals per a la realització de tasques com el reconeixement de parla, la traducció automàtica o la predicció de sèries temporals, on les dependències temporals i de context són essencials. En comparació amb les xarxes neuronals estàtiques, les RNNs ofereixen una representació més dinàmica i flexible de les dades, podent modelar relacions al llarg termini dins d'una seqüència. Tot i això, malgrat el seu potencial, els primers models de RNN presentaven dificultats en l'entrenament, com el problema del gradient que s'esvaeix, on al entrenar una xarxa neuronal amb el mètode de retropropagació, a mesura que les dades es mouen d'una capa a una altra es van fer cada cop més petites, enlentint o directament parant el procés d'entrenament, o del gradient que explota, on les dades creixen de manera exponencial entre capes, produint el mateix efecte que el gradient que s'esvaeix, fets que limiten l'aplicació pràctica fins a la introducció de variants més estables com les LSTM i les GRU a finals dels anys 1990.

3.4. Xarxes neuronals artificials modernes (ANNs)

Les xarxes neuronals han recorregut un llarg camí des dels seus inicis, evolucionant en complexitat i eficiència amb l'avenç de la tecnologia i la investigació. Malgrat aquesta evolució, el fonament de les xarxes neuronals s'ha mantingut majorment inalterat. Les xarxes neuronals actuals es basen en els mateixos principis en els que es basaven les primeres xarxes neuronals, com ara el perceptró [8], i més tard els MLPs [12], les CNNs [17] i les RNNs. Aquestes xarxes estan estructurades en tres tipus de capes. La capa d'entrada rep les dades inicials, on cada neurona representa una característica específica dels inputs. Les capes ocultes, que poden ser múltiples, són les responsables de processar aquestes dades i extreure característiques complexes a través de connexions ponderades. Cada neurona d'una capa oculta combina les entrades que rep, aplica un pes i una funció d'activació abans d'enviar la informació a la següent capa. Finalment, la capa de sortida presenta el resultat del model, que pot ser una classificació, una predicció numèrica o una altra forma de resultat.

Els pesos assignats a cada connexió determinen la influència de l'entrada sobre la sortida. A

més, les neurones poden disposar de biaixos, que afegeixen una constant per assegurar que les sortides puguin ser ajustades independentment de les entrades. Les funcions d'activació són fonamentals per a la creació de no linearitats dins del model, permetent que les xarxes aprenguin relacions complexes. Algunes de les funcions d'activació més populars avui dia inclouen la ReLU (Rectified Linear Unit), que retorna 0 per a entrades negatives i la pròpia entrada per a entrades positives, la sigmoide, que comprimeix les sortides entre 0 i 1, i la tanh, que les comprimeix entre -1 i 1.

El procés d'aprenentatge d'una ANN moderna es realitza en diversos passos. Primer, es fa una propagació cap endavant, on les dades es transmeten de la capa d'entrada fins a la sortida, passant per les capes ocultes i aplicant les funcions d'activació. Després, es calcula l'error comparant la sortida obtinguda amb la sortida esperada. Finalment, es realitza la retropropagació, un procés mitjançant el qual els pesos i biaixos són ajustats per reduir l'error. Utilitzant tècniques com el gradient descendent, la xarxa actualitza els pesos de manera que les futures prediccions siguin més precises.

Des dels anys 90, les xarxes neuronals han experimentat una evolució significativa no tant per la tecnologia en si, sinó pel seu escalat en termes de complexitat i capacitat. Inicialment, aquestes xarxes podien tenir centenars de milers de paràmetres (o neurones), limitades per la disponibilitat de dades i la potència de càlcul de la època. Amb l'accés a grans quantitats de dades gràcies a l'aparició i popularització d'internet i a maquinaria més potent, com les unitats de processament gràfic (GPUs), les xarxes neuronals han crescut fins a arribar als milers de milions de paràmetres, permetent un modelatge més precís i detallat de patrons complexos, com ara la parla. Aquest increment en l'escala ha facilitat el desenvolupament d'intel·ligència artificial més avançada, capaç d'aprendre de conjunts de dades massius i realitzar tasques que abans eren impensables, com ara el reconeixement d'imatges a gran escala, la traducció automàtica precisa i la generació de contingut de forma creativa.

Les arquitectures convencionals com les CNNs i les RNNs continuen utilitzant-se per les tasques pels quals van ser dissenyades (CNNs per visió, RNNs per dades seqüencials), però al mateix temps han aparegut alternatives sovint més eficients o millor adaptades a problemes moderns, com els transformers per NLP (processament de llenguatge natural) i seqüències llargues, variants d'object-detection com YOLOv8 [18] per detecció d'objectes en temps real en visió per computador, GANs (Generative Adversarial Networks) [19] per generació de contingut sintètic com imatges o vídeos i arquitectures híbrides que combinen components (per exemple: CNN+transformer), que en molts casos superen o complementen les CNN/RNN tradicionals, i que poc a poc van reemplaçant a aquestes xarxes. En els últims anys han estat sobretot els transformers els que s'han imposat com l'arquitectura més utilitzada i sovint la més efectiva en moltes tasques (especialment en NLP, però també en visió i multimodalitat), en part per la popularitat que intel·ligències artificials de processament de llenguatge basades en aquesta arquitectura han guanyat en aquest període, com ara el ChatGPT o Claude.

Els transformers apareixen fa relativament poc, més concretament a l'any 2017, amb la publicació de l'article *Attention Is All You Need* de Vaswani et al. [20]. En aquest treball, s'introdueixen els transformers com una nova arquitectura de xarxa neuronal basada exclusivament en mecanismes d'atenció, eliminant així la necessitat de recurrència o convolució, que fins al moment caracteritzen les arquitectures anteriors com les RNNs o CNNs.

Els transformers es basen en el mecanisme d'atenció, en concret en el mecanisme d'autoatenció, el qual permet a cada element d'una seqüència ponderar la rellevància de tots els altres elements

de la mateixa seqüència per generar la seva pròpia representació.

Aquest procés es duu a terme mitjançant capes d'atenció múltiple (multi-head attention layers), que permeten que el model aprengui diferents tipus de relacions i dependències entre paraules o unitats de dades de manera simultània. A diferència de les RNNs, que processen les dades seqüencialment, els transformers poden processar tots els elements en paral·lel, fet que redueix significativament el temps d'entrenament i millora l'escalabilitat del model.

A més del mecanisme d'atenció, els transformers incorporen una sèrie de components addicionals com les "positional encodings" o codificacions posicionals, que afegeixen informació sobre la posició relativa dels elements dins la seqüència, i les "feed-forward networks" o xarxes de prealimentació, capes completament connectades que operen sobre cada posició de manera independent. Aquesta combinació de components fa que els transformers siguin extremadament flexibles i adaptables a diferents tipus de dades i tasques.

Els avantatges dels transformers són nombrosos. Ofereixen un rendiment superior en tasques de processament de llenguatge natural (NLP), permeten entrenar models amb una quantitat massiva de dades i paràmetres, i són altament paral·lelitzables, cosa que redueix els costos computacionals en comparació amb altres arquitectures seqüencials. Aquestes característiques han impulsat el desenvolupament dels grans models de llenguatge (LLMs), com la sèrie GPT (Generative Pre-trained Transformer), BERT (Bidirectional Encoder Representations from Transformers) o T5 (Text-To-Text Transfer Transformer), que han revolucionat el camp de la intel·ligència artificial moderna.

Avui dia, els transformers constitueixen la base de la majoria dels avenços en IA, no només en processament de llenguatge, sinó també en visió per computador, bioinformàtica, generació de codi i àrees multimodals que combinen text, imatge, àudio i vídeo. La seva capacitat per aprendre representacions contextuais complexes i generalitzar coneixement a tasques diverses els ha convertit en una de les fites més significatives en la història de la intel·ligència artificial i el deep learning, marcant l'inici d'una nova era dominada pels models fundacionals i els sistemes d'aprenentatge a gran escala.

Una part substancial del progrés recent en xarxes neuronals, incloent-hi l'aparició i consolidació dels transformers, no pot atribuir-se únicament a innovacions en l'arquitectura dels models. Aquesta evolució ha estat possible gràcies a una convergència de factors tecnològics, entre els quals destaca la millora significativa de les eines de programació, la disponibilitat d'infraestructures computacionals d'alt rendiment i l'accés a volums massius de dades digitalitzades. En aquest context, els llenguatges de programació contemporanis han tingut un paper fonamental. Python, en particular, s'ha posicionat com el llenguatge predominant en "machine learning" no només per la seva sintaxi accessible, sinó també per la maduresa d'un ampli conjunt de biblioteques especialitzades que faciliten totes les etapes del cicle de vida dels d'aquests models. Eines com TensorFlow, Keras, Pytorch i JAX proporcionen eines d'alt nivell que permeten definir i treballar amb arquitectures complexes d'una manera molt més senzilla i estructurada, optimitzar sèries numèriques de manera eficient i la integració nativa amb GPU i TPU, fet que permet entrenar models de gran escala que haurien estat inviables fa només uns anys. Paral·lelament, l'existència de paquets orientats a la gestió i preprocesament de dades com NumPy, Pandas o Dask, ha fet possible organitzar, transformar i manipular volums ingents d'informació d'una manera sistemàtica i reproduïble, cosa que ha facilitat notablement l'entrenament d'aquests models. Tot plegat ha generat un entorn on el desenvolupament, experimentació i validació de models com-

plexos és molt més accessible, accelerant la innovació i contribuint directament a l'expansió de mètodes d'aprenentatge profund cada vegada més sofisticats.

Amb l'aparició de noves arquitectures neuronals i tecnologies d'aprenentatge automàtic, també han sorgit mètodes més especialitzats per classificar i avaluar els models segons les necessitats i la naturalesa de cada tasca. En el cas de la classificació, avui dia s'utilitzen mètriques com la precisió de la resposta obtinguda, el recall, que mesura la capacitat del model per identificar correctament els elements positius d'una classe, i la F1-score, que representa la mitjana harmònica entre precisió i recall, equilibrant els dos aspectes quan cap d'ells no pot ser ignorat, que permeten analitzar diversos aspectes del comportament del model, especialment en situacions amb classes desequilibrades. Per a tasques de regressió, en canvi, és habitual emprar mesures com l'error quadràtic mitjà (MSE) o l'error absolut mitjà (MAE), que quantifiquen la magnitud de les discrepàncies entre les prediccions i els valors reals. També s'utilitzen eines més específiques, com la matriu de confusió en problemes de múltiples classes, l'AUC-ROC (Area Under the Receiver Operating Characteristic Curve) [21] en classificació binària, el BLEU (Bilingual Evaluation Understudy) [22] en traducció automàtica o el mAP (mean Average Precision) [23] en detecció d'objectes, cadascuna pensada per capturar aspectes concrets del rendiment. L'elecció d'aquestes mètriques és essencial, ja que proporciona una visió precisa sobre la qualitat del model i orienta les millores necessàries per adequar-lo als objectius de l'aplicació concreta.

Un exemple clàssic que il·lustra de manera integrada els principis fonamentals exposats fins ara és el conjunt de dades MNIST, un conjunt format per imatges de dígitos manuscrits. Aquest recurs, àmpliament utilitzat en entorns educatius i experimentals, permet observar com diferents arquitectures, des de perceptrons multicapa fins a xarxes convolucionals, aborden una mateixa tasca de classificació. Per exemple, un model inicialment simple pot constar d'una capa d'entrada de 784 neurones (derivades dels 28×28 píxels que té cada imatge), una o diverses capes ocultes i una capa de sortida amb 10 neurones corresponents a les classes possibles (números del 0 al 9). Mitjançant el procés d'entrenament basat en propagació cap endavant i retropropagació del gradient, la xarxa aprèn a extreure patrons visuals rellevants a partir de milers d'imatges etiquetades. En aquest treball aquest mateix conjunt s'utilitzarà de manera il·lustrativa per demostrar com funcionen exactament les xarxes prèviament tractades, i per exemplificar les avantatges, desavantatges i diferències que poden tenir les xarxes de polsos respecte a les xarxes neuronals convencionals ja comentades.

3.5. Limitacions de les ANNs

Les xarxes neuronals artificials, malgrat els grans avenços i l'eficàcia demostrada en nombroses aplicacions, presenten limitacions que condicionen el seu desplegament i la seva adaptabilitat a certs entorns. En primer lloc, el cost computacional i energètic associat a l'entrenament i a la inferència de models grans és molt elevat. L'entrenament de xarxes amb milions o milers de milions de paràmetres requereix centres de càlcul amb GPU/TPU especialitzades, hardware que requereix d'un gran consum d'electricitat, i un temps significatiu d'entrenament, cosa que suposa costos econòmics i ambientals notables. Això també es tradueix en una barrera d'entrada per a organitzacions petites i investigadors amb recursos limitats.

Una altra limitació és la manca de temporalitat natural en moltes arquitectures estàndard. Tot i que les RNNs i variants com LSTM/GRU foren concebudes per tractar dependències temporals, moltes arquitectures modernes, com per exemple els transformers, requereixen de mecanismes

addicionals per captar de forma explícita la dinàmica temporal en dades contínues o en fluxos en temps real, fet que pot complicar el disseny de models per aplicacions com control en temps real o sèries temporals amb dependències llargues i no estacionàries.

Pel que fa a la correspondència amb el cervell humà, les ANNs no reproduïen la major part dels principis biològics del processament neuronal. El seu funcionament és una aproximació matemàtica inspirada en el cervell, però diferent en arquitectura, dinàmiques i eficiència energètica. Això implica que, malgrat algunes capacitats anàlogues (com l'aprenentatge a partir d'exemples), les xarxes artificials no presenten les mateixes propietats de robustesa, plasticitat i eficiència que caracteritzen el cervell humà.

L'escalabilitat amb eficiència és un repte addicional. L'augment de grandària dels models (per exemple, en LLMs) acostuma a portar millors resultats, però la millora no és lineal respecte al nombre de paràmetres. Sovint cal afegir ordres de magnitud més de paràmetres per obtenir guanys incrementals de precisió. En models molt grans com els LLMs actuals, per millorar notablement la qualitat cal incorporar molts més paràmetres, fet que fa que el cost d'entrenament i el consum energètic augmentin de manera quasi-exponencial respecte a les millores obtingudes. Això empitjora la relació cost-benefici i complica la gestió pràctica, fent necessari revisar dissenys, tècniques d'eficiència (poda, quantització, knowledge distillation) i estratègies d'entrenament per contenir costos i consum, i limita l'escalament d'aquests models passat de models massius.

Finalment, hi ha limitacions rellevants per a "edge computing" o computació perifèrica, on el processament de dades i la presa de decisions es fan pròxims a la font de les dades per reduir la latència, i sistemes embarcats. La majoria de models d'alt rendiment són massa grans o exigents per a dispositius amb recursos limitats (CPU de baixa potència, memòria reduïda, restriccions d'energia), cosa que obliga a recórrer a tècniques de compressió, quantització, poda o a dissenys específics "light-weight" o de baix pes o cost computacional, que sovint impliquen una pèrdua de precisió o capacitat. Aquestes restriccions condicionen l'adopció de les ANNs en aplicacions mòbils, IoT (Internet of Things) i en entorns amb requisits estrictes d'energia i latència.

3.6. Xarxes neuronals de polsos (SNNs)

- Motivació neuromòrfica.
- Codificació temporal.
- Algorismes d'entrenament.
- Simuladors disponibles.
- Casos d'ús actuals i futurs.

4. Fonament tècnics de les SNNs

- Comparació tècnica: ANN vs SNN.
- Models de neurones: Integrate-and-Fire, Leaky Integrate-and-Fire (LIF), etc.
- Codificació temporal (rate coding, temporal coding, etc.).
- Algoritmes d'entrenament (STDP, surrogate gradient, etc.).
- Simuladors existents: Brian2, NEST, BindsNET, SpikingJelly, etc.

5. Desenvolupament pràctic

5.1. Entrenament d'una ANN per MNIST

- Descripció del dataset MNIST.
- Arquitectura seleccionada para la ANN (MLP simple o CNN).
- Eines utilitzades (ex., PyTorch).
- Resultats de entrenament i validació.
- Mètriques d'evaluació.

5.2. Conversió ANN → SNN

- Maneres existents per la conversió ANN a SNN (rate-based conversion, etc.).
- Implementació pròpia o us/adaptació de llibreries.
- Explicació del procés de conversió.
- Resultats de inferència con la SNN convertida.
- Limitacions observades.

5.3. Disseny d'una arquitectura hardware neuromòrfica (Si dona temps)

- Justificació de la necessitat de maquinari específic.
- Descripció d'arquitectura maquinari proposada.
- Neurones i sinapsi com a blocs funcionals.
- Controlador de spikes, temporització, etc.
- Eines usades (e.g., llenguatge HDL, simuladors, disseny esquemàtic).
- Diagrama funcional i/o esquemàtic.
- Possibles millores o extensions (FPGA, xips neuromòrfics com Loihi, etc.).

6. Resultats

- Comparativa de rendiment: ANN vs SNN.
- Eficiència energètica estimada.
- Dificultats trobades durant el desenvolupament.
- Reflexió sobre la viabilitat de l'ús de SNNs a la pràctica.
- Possibles futurs usos.

7. Pressupost

8. Impacte ambiental

Conclusions

Agraïments

Gracies

Bibliografia

- [1] A. N. W. Bertrand Russell, *Principia Mathematica*, Vols. I-III. Cambridge University Press, 1910-1913.
- [2] W. McCulloch y W. Pitts, «A Logical Calculus of the Ideas Immanent in Nervous Activity,» *The Bulletin of Mathematical Biophysics*, 1943, Disponible a: <https://doi.org/10.1007/BF02478259>, Consultat: 20/08/2025.
- [3] A. Turing, «Computing Machinery and Intelligence,» *Mind*, vol. LIX, n.º 236, págs. 433-460, 1950, Disponible a: <https://academic.oup.com/mind/article-abstract/LIX/236/433/986238>, Consultat: 20/08/2025.
- [4] J. McCarthy, M. L. Minsky, N. Rochester y C. E. Shannon, «A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence,» Dartmouth College, inf. téc., 1956, Disponible a: <http://www-formal.stanford.edu/jmc/history/dartmouth/dartmouth.html>, Consultat: 22/08/2025.
- [5] A. Newell, J. C. Shaw y H. A. Simon, «The Logic Theory Machine: A Complex Information Processing System,» en *Proceedings of the Western Joint Computer Conference*, Spartan Books, 1956, págs. 99-103.
- [6] A. Newell, J. C. Shaw y H. A. Simon, «Report on a General Problem Solver,» Carnegie Institute of Technology, Technical Report Research Report, 1959, Disponible a: https://bitsavers.trailing-edge.com/pdf/rand/ipl/P-1584_Report_On_A_General_Problem-Solving_Program_Feb59.pdf, Consultat: 24/08/2025.
- [7] A. L. Samuel, «Some Studies in Machine Learning Using the Game of Checkers,» *IBM Journal of Research and Development*, vol. 3, n.º 3, págs. 210-229, 1959, Disponible a: <https://ieeexplore.ieee.org/abstract/document/5392560>, Consultat: 27/08/2025.
- [8] F. Rosenblatt, «The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain,» *Psychological Review*, vol. 65, n.º 6, págs. 386-408, 1958, Disponible a: <https://psycnet.apa.org/record/1959-09865-001>, Consultat: 27/08/2025.
- [9] Georgetown University e IBM, *Demonstration of Automatic Translation - Georgetown-IBM Experiment*, Demonstration/press release, Disponible a: https://www.ibm.com/ibm/history/exhibits/translation/translation_1.html, Consultat: 27/08/2025, 1954.
- [10] D. G. Bobrow, «STUDENT - A Computer Program for Solving Problems in Elementary Algebra,» Massachusetts Institute of Technology, Project MAC, Technical Report MIT Project MAC TR-41, 1964, Disponible a: <https://dspace.mit.edu/handle/1721.1/149326>, Consultat: 27/08/2025.
- [11] M. Minsky y S. Papert, *Perceptrons: An Introduction to Computational Geometry*. Cambridge, MA: MIT Press, 1969.
- [12] D. E. Rumelhart, G. E. Hinton y R. J. Williams, «Learning representations by back-propagating errors,» *Nature*, vol. 323, n.º 6088, págs. 533-536, 1986, Disponible a: <https://www.nature.com/articles/323533a0>, Consultat: 08/09/2025.
- [13] R. Hahnloser, H. Sprekeler y H. S. Seung, «Digital communications and the sigmoid function,» *Journal of Computational Neuroscience*, vol. 9, n.º 2, págs. 195-203, 2000.

- [14] X. Glorot e Y. Bengio, «Deep Sparse Rectifier Neural Networks,» en *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics*, Disponible a: <https://aistats.org/aistats2011/proceedings.html>, Consultat: 14/09/2025, 2011, pàgs. 315-323.
- [15] K. Fukushima, «Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position,» *Biological Cybernetics*, vol. 36, n.º 4, pàgs. 193-202, 1980, Disponible a: <https://link.springer.com/article/10.1007/BF00344251>, Consultat: 14/09/2025.
- [16] K. Fukushima, «Visual Feature Extraction by a Multilayered Network of Analog Threshold Elements,» *IEEE Transactions on Systems Science and Cybernetics*, vol. 5, n.º 4, pàgs. 322-333, 1969, Disponible a: <https://ieeexplore.ieee.org/document/4082265>, Consultat: 14/09/2025.
- [17] Y. LeCun, L. Bottou, Y. Bengio y P. Haffner, «Gradient-Based Learning Applied to Document Recognition,» *Proceedings of the IEEE*, vol. 86, n.º 11, pàgs. 2278-2324, 1998, Disponible a: <https://ieeexplore.ieee.org/document/726791>, Consultat: 14/09/2025.
- [18] G. Jocher y et al., «YOLOv8: Open-Source Neural Networks for Object Detection,» *Zenodo*, 2023. DOI: [10.5281/zenodo.1234567](https://doi.org/10.5281/zenodo.1234567)
- [19] I. Goodfellow et al., «Generative Adversarial Nets,» en *Advances in Neural Information Processing Systems*, 2014.
- [20] A. Vaswani et al., «Attention is All you Need,» en *Advances in Neural Information Processing Systems*, I. Guyon et al., eds., vol. 30, Curran Associates, Inc., 2017.
- [21] T. Fawcett, «An introduction to ROC analysis,» *Pattern Recognition Letters*, vol. 27, n.º 8, pàgs. 861-874, 2006.
- [22] K. Papineni, S. Roukos, T. Ward y W.-J. Zhu, «BLEU: a Method for Automatic Evaluation of Machine Translation,» en *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, 2002, pàgs. 311-318.
- [23] M. Everingham, L. Van Gool, C. K. Williams, J. Winn y A. Zisserman, «The PASCAL Visual Object Classes (VOC) Challenge,» *International Journal of Computer Vision*, vol. 88, n.º 2, pàgs. 303-338, 2010.

Anex

Codi

Logs d'entrenament

Esquemes Hardware